

Санкт-Петербургский Национальный Исследовательский
Университет Информационных Технологий, Механики и Оптики

Факультет инфокоммуникационных технологий

Лабораторная работа №1
Вариационный вывод и автокодировщики.

Выполнил
Стафеев Иван Алексеевич

Группа
К3221

Проверил
Исаков Артем Олегович

Санкт-Петербург,
2025

СОДЕРЖАНИЕ

Стр.

ВВЕДЕНИЕ	3
1 Теоретические сведения	4
1.1 Вариационные автокодировщики (VAE)	4
1.2 Условные VAE (CVAE)	4
1.3 Метрика FID	5
2 Реализация моделей	6
2.1 VAE	6
2.2 Использование готовой модели	7
3 CVAE	9
ЗАКЛЮЧЕНИЕ	10
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	11

ВВЕДЕНИЕ

Цель работы: ознакомление с устройством вариационных автоэнкодеров (VAE) и реализация на Python с использованием наборов данных Kaggle и предварительно обученных моделей Hugging Face.

1 Теоретические сведения

1.1 Вариационные автокодировщики (VAE)

Вариационный автокодировщик (VAE) — это генеративная модель, которая обучается восстанавливать входные данные и формировать непрерывное, регулярное латентное пространство, из которого можно сэмплировать новые осмысленные примеры.

В отличие от обычных автокодировщиков, VAE моделирует не точку в латентном пространстве, а распределение. Энкодер выдаёт параметры нормального распределения (среднее μ и дисперсию σ^2), из которого затем выбирается латентный вектор z : $z \sim \mathcal{N}(\mu, \sigma^2)$

Декодер восстанавливает данные по этому вектору: $\hat{x} = D(z)$.

Функция потерь

Функция потерь VAE состоит из двух слагаемых:

- Ошибка реконструкции, чаще всего это бинарная кросс-энтропия:

$$\mathcal{L}_{\text{rec}} = \mathbb{E}_{q(z|x)} [-\sum_{i=1}^n (x_i \log \hat{x}_i + (1 - x_i) \log(1 - \hat{x}_i))]$$

- KL-дивергенция между аппроксимированным постериорным $q(z|x)$ и априорным $p(z) = \mathcal{N}(0, I)$:

$$D_{\text{KL}}(q(z|x) \parallel p(z)) = \frac{1}{2} \sum_{i=1}^d (\mu_i^2 + \sigma_i^2 - \log \sigma_i^2 - 1)$$

Итоговая функция потерь: $\mathcal{L}_{\text{VAE}} = \mathcal{L}_{\text{rec}} + D_{\text{KL}}(q(z|x) \parallel p(z))$

1.2 Условные VAE (CVAE)

Условный вариационный автокодировщик (CVAE) расширяет VAE, позволяя учитывать дополнительную информацию — например, метку класса y .

В такой модели:

- Энкодер получает на вход (x, y) и возвращает параметры распределения $q(z|x, y)$.
- Декодер восстанавливает данные по z и y : $\hat{x} = D(z, y)$.

Функция потерь сохраняет форму, но становится условной:

$$\mathcal{L}_{\text{CVAE}} = \mathbb{E}_{q(z|x,y)}[-\log p(x|z,y)] + D_{\text{KL}}(q(z|x,y) \parallel p(z|y))$$

Часто используют независимое априорное распределение $p(z|y) = \mathcal{N}(0, I)$ для упрощения.

1.3 Метрика FID

Для количественной оценки качества сгенерированных изображений используется метрика FID. Она измеряет схожесть между распределениями признаков реальных и сгенерированных изображений, извлечённых из промежуточного слоя сети Inception.

Пусть μ_r, Σ_r — среднее и ковариация признаков реальных изображений, а μ_g, Σ_g — для сгенерированных. Тогда FID вычисляется как:

$$\text{FID} = \|\mu_r - \mu_g\|^2 + \text{Tr} \left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2} \right)$$

Чем меньше FID, тем ближе распределения и выше качество генерации.

2 Реализация моделей

Код моделей и инфраструктуры для их обучения можно посмотреть в источнике [1].

Для обучения был выбран набор данных MNIST dataset, содержащий 60 тысяч тренировочных и 10 тысяч тестовых изображений 28x28 пикселей.

2.1 VAE

Обычный VAE был релизован с использованием сверточных слоев. Обучение проводилось 20 эпох с оптимизатором Adam. Графики обучения показаны на рисунке 1




Рисунок 1 — Графики обучения VAE

Результат реконструкции набора из 10 цифр и генерации 64 цифр из латентного пространства показаны на рисунке 2 и 3. На глаз результат можно считать достаточно хорошим.




Рисунок 2 — Результат реконструкции



Рисунок 3 — Результат генерации

Для количественной оценки модели была использована метрика FID. Для этого сначала была обучена модель LeNet для извлечения значений фичей. Значение FID для модели получилось **288.12** - много, но это за 20 эпох и без подбора гиперпараметров.

2.2 Использование готовой модели

Для сравнения была использована готовая модель Maksimk04/Digits_autoencoder_mnist с HuggingFace. Результаты реконструкции и генерации показаны на рисунках 4 и 5. Значение FID получилось равным **1740.70**, то есть можно утверждать, что реализованная самостоятельно модель лучше генерирует изображения.




Рисунок 4 — Результат реконструкции



Рисунок 5 — Результат генерации

3 CVAE

Условный VAE (CVAE) был реализован на основе обычного CVAE с применением onehot-преобразований для меток. Модель обучалась 12 эпох. Результат генерации показан на рисунке 6. Результат удовлетворительный.




Рисунок 6 — Результат генерации для CVAE

ЗАКЛЮЧЕНИЕ

В результате работы были реализованы и протестированы модели VAE и CVAE. Модели успешно восстанавливают и генерируют изображения, формируя осмысленное латентное пространство. Количественная оценка генерации моделями далека от идеала, что подтверждается метрикой FID, однако результаты могут быть улучшены подбором гиперпараметров и изменением архитектур моделей.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Блокнот с кодом на Google Colab: [Электронный ресурс]. - URL: https://colab.research.google.com/drive/1dnQWvo3iweXVX_3K3JRlc10odjVR7w5S?usp=sharing