

Санкт-Петербургский Национальный Исследовательский
Университет Информационных Технологий, Механики и Оптики

Факультет инфокоммуникационных технологий

Лабораторная работа №2
Генеративно-сопоставительные сети (GAN).

Выполнил
Стафеев Иван Алексеевич

Группа
К3221

Проверил
Исаков Артем Олегович

Санкт-Петербург,
2025

СОДЕРЖАНИЕ

	Стр.
ВВЕДЕНИЕ	3
1 Теоретические сведения	4
1.1 GAN	4
1.2 DCGAN.....	4
2 Реализация моделей	5
ЗАКЛЮЧЕНИЕ	8
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	9

ВВЕДЕНИЕ

Цель работы: ознакомление с принципами работы генеративно-сопоставительных сетей (GAN), изучение их архитектуры и практическая реализация GAN для генерации изображений.

1 Теоретические сведения

1.1 GAN

Генеративные состязательные сети (Generative Adversarial Networks, GAN) — это класс генеративных моделей, в которых две нейросети — генератор и дискриминатор — обучаются совместно в режиме игры с нулевой суммой.

- Генератор $G(z)$ принимает на вход случайный шум $z \sim p_z(z)$ и пытается сгенерировать реалистичные данные $\hat{x} = G(z)$.
- Дискриминатор $D(x)$ оценивает вероятность того, что входные данные x являются реальными, а не сгенерированными.

Обучение сводится к оптимизации минимаксной функции:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

Генератор стремится минимизировать эту функцию, заставляя дискриминатор ошибаться, а дискриминатор — максимально точно отличать настоящие данные от поддельных.

1.2 DCGAN

DCGAN — улучшение классического GAN, в котором генератор и дискриминатор реализованы с использованием глубоких сверточных нейронных сетей. Это позволяет модели лучше захватывать пространственные зависимости и получать более качественные изображения.

Основные особенности DCGAN:

- Использование сверточных слоев вместо полносвязных.
- Применение транспонированных свёрток (deconvolution) в генераторе для увеличения размерности.
- Отказ от полносвязных слоёв в пользу сверточных для устойчивого обучения.
- Использование активации LeakyReLU в дискриминаторе и ReLU с Batch Normalization в генераторе.

2 Реализация моделей

Код моделей и инфраструктуры для их обучения можно посмотреть в источнике [1].

Для обучения был выбран набор данных MNIST dataset, содержащий 60 тысяч тренировочных и 10 тысяч тестовых изображений 28x28 пикселей.

В работе использовались стандартные значения гиперпараметров (Размерность латентного пространства = 100 позволяет генератору получить достаточно информации для генерации изображения, learning rate = 0.001 не допускает исчезновения или сильного возрастания градиентов).

Модель для обычного GAN показала плохие результаты обучения (рисунок 1), видимо, из-за того, что она была некорректно урезана из более сильной модели обычного GAN (то есть ошибка в архитектуре модели). Также имеет место не самый удачный подбор гиперпараметров.




Рисунок 1 — Графики обучения GAN

Видно, что вначале произошел коллапс мод, который затем пропал, но модель все равно не смогла выйти на качественную генерацию. получилась ситуация, что генератор нашел точку в латентном пространстве, которую дискриминатор не распознает как сгенерированную, и эта единственная точка (то есть далее единственное сгенерированное изображение) получается для всех входных данных.




Рисунок 2 — Графики обучения DCGAN

Реализованная модель DCGAN показала значительно более качественные результаты (рисунок 2) при обучении на 30 эпохах, видна небольшая осцилляция генератора и дискриминатора. Сгенерированные изображения (3) вышли относительно неплохими - большая часть цифр четкая и легко читаемая.



Рисунок 3 — Сгенерированные изображения

Для контроля качества генерации была реализована интерполяция в латентном пространстве (рисунок 4). Модель плавно и качественно переходит от одной цифре к другой, выявляя характерные их черты (засечки, дуги и т.д.)



Рисунок 4 — Интерполяция в латентном пространстве

ЗАКЛЮЧЕНИЕ

В ходе выполнения работы были изучены теоретические основы генеративно-сопоставительных сетей (GAN), включая их базовую архитектуру и улучшенную версию — DCGAN, были реализованы обе модели. Обычный GAN показал плохие результаты генерации, видимо, в процессе реализации были допущены ошибки в архитектуре модели. DCGAN показал достаточно неплохие результаты после обучения.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Блокнот с кодом на Google Colab: [Электронный ресурс]. - URL: https://colab.research.google.com/drive/1Jcw0WVpLocVCAHgDoeub0BLtjo_jRbGe?usp=sharing