

Санкт-Петербургский Национальный Исследовательский
Университет Информационных Технологий, Механики и Оптики

Факультет инфокоммуникационных технологий

Лабораторная работа №3
Диффузионные модели, архитектура U-Net.

Выполнил
Стафеев Иван Алексеевич

Группа
К3221

Проверил
Исаков Артем Олегович

Санкт-Петербург,
2025

СОДЕРЖАНИЕ

Стр.

ВВЕДЕНИЕ	3
1 Теоретические сведения	4
1.1 Диффузионные модели	4
1.2 Прямой и обратный процессы	4
1.3 U-Net	4
1.4 DDIM-сэмплирование	5
1.5 Шумовые расписания	5
2 Реализация моделей	6
ЗАКЛЮЧЕНИЕ	9
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	10

ВВЕДЕНИЕ

Цель работы: изучение и практическое применение математических основ диффузионных моделей — одного из современных подходов в генеративном искусственном интеллекте.

1 Теоретические сведения

1.1 Диффузионные модели

Диффузионные модели (Diffusion Models) — это класс генеративных моделей, которые обучаются постепенно «обращать» процесс добавления шума к данным. Идея заключается в том, чтобы поэтапно добавлять к изображению случайный шум, а затем обучить модель обращать этот процесс, восстанавливая изображение из чистого шума.

1.2 Прямой и обратный процессы

Прямой (диффузионный) процесс задаётся как последовательность:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

где x_0 — исходное изображение, β_t — дисперсия шума на шаге t (шумовое расписание).

Обратный процесс моделируется нейросетью $\varepsilon_\theta(x_t, t)$, которая обучается предсказывать добавленный шум на каждом шаге:

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{x_0, \varepsilon, t} [\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2]$$

1.3 U-Net

В роли модели ε_θ обычно используется архитектура **U-Net**, состоящая из энкодера и декодера с пропусками (skip-connections), что позволяет эффективно обрабатывать как глобальные, так и локальные особенности изображения. Для учёта взаимосвязей между отдалёнными участками изображения в U-Net добавляются блоки **self-attention**, особенно на средних уровнях латентного пространства.

1.4 DDIM-сэмплирование

Для ускорения генерации применяется детерминированный вариант сэмплирования — **DDIM** (Denoising Diffusion Implicit Models). Он позволяет восстанавливать изображения за меньшее число шагов без ухудшения качества, заменяя стохастический процесс детерминированным:

$$x_{t-1} = \sqrt{\alpha_{t-1}} \left(\frac{x_t - \sqrt{1 - \alpha_t} \varepsilon_\theta(x_t, t)}{\sqrt{\alpha_t}} \right) + \eta \cdot \sigma_t$$

1.5 Шумовые расписания

От выбора расписания β_t (шумовой дисперсии) зависит поведение модели. Наиболее популярны:

- Линейное: β_t увеличивается равномерно.
- Косинусное: обеспечивает медленное нарастание шума на первых шагах.
- Обратные логарифмы и экспоненты — используются для контроля плотности информации.

Диффузионные модели достигли выдающихся результатов в генерации изображений, превзойдя GAN по качеству и устойчивости обучения.

2 Реализация моделей

Код моделей и инфраструктуры для их обучения можно посмотреть в источнике [1].

Для обучения был выбран набор данных MNIST dataset, содержащий 60 тысяч тренировочных и 10 тысяч тестовых изображений 28x28 пикселей.

В начале были протестированы различные расписания шумов - фиксированное, линейное и косинусное - с целью определения наиболее подходящего для обучения (рисунки 1, 2 и 3). Было выбрано косинусное расписание, так как при его использовании шум добавляется наиболее плавно по сравнению с остальными расписаниями, соответственно, изображение не так быстро теряет качественные детали.




Рисунок 1 — Фиксированное расписание шума




Рисунок 2 — Линейное расписание шума




Рисунок 3 — Косинусное расписание шума

В качестве денойзера в диффузионной модели была использована U-Net с применением DDIM-сэмплирования и attention-механизмов. В ходе обучения в течение 30 эпох диффузионная модель стала показывать хорошие для такого количества эпох результаты генерации (рисунок 4 и 5).



Рисунок 4 — Первая удачная генерация на 17 эпохе




Рисунок 5 — Результаты генерации после 30 эпох

Для количественной оценки качества генерации были посчитаны метрики FID - **598.16** - и IS - **1.92**, то есть количественно модель далека от хороших результатов. Причиной тому может быть некорректный подбор гиперпараметров, ошибки при создании архитектуры и недостаточное количество эпох обучения.

ЗАКЛЮЧЕНИЕ

В ходе работы были изучены и реализованы диффузионные модели с архитектурой U-Net и DDIM-сэмплированием. Проведён эксперимент с различными шумовыми расписаниями, наилучшие результаты показало косинусное. Модель успешно обучалась на MNIST, однако итоговые метрики остаются низкими, что требует дальнейшей доработки.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Блокнот с кодом на Google Colab: [Электронный ресурс]. - URL: <https://colab.research.google.com/drive/1IF2f117g4Sc5XJ8Y5IA6Fn4eUpnq7Inr?usp=sharing>